

Séries Temporais

Econometria II · UFBA

Prof. Pablo Castro

Parte I

- **Processos estacionários**
- Processos não estacionários
- Processos com tendência determinística
- Metodologia de Box-Jenkins

Parte II

- Previsão
- Cointegração
- Autoregressão vetorial

Introdução

O que é uma Série Temporal?

Definição

Uma série temporal é qualquer conjunto de observações ordenadas no tempo.

Exemplos

- Valores diários de poluição em Salvador
- Valores mensais de temperatura em Ibotirama-BA
- Índices diários da Bolsa de Valores de SP
- Precipitação atmosférica anual em Fortaleza
- Número médio anual de manchas solares
- Registro de marés no porto de Aratu

Observação

Os cinco primeiros exemplos são séries *discretas*; o registro de marés é, em princípio, uma série *contínua*.

Série discreta

Observações registradas em instantes de tempo isolados (dia, mês, ano etc.).

Série contínua

Observações registradas continuamente ao longo de um intervalo $[0, T]$.

Amostragem: uma série contínua pode ser convertida em discreta amostrando-a em intervalos de tempo iguais Δt , gerando N pontos, com

$$N = \frac{T}{\Delta t}.$$

Exemplo

Registrando a temperatura do ar de hora em hora ($\Delta t = 1\text{h}$) ao longo de um dia ($T = 24\text{h}$): $N = 24/1 = 24$ observações.

Notação: Série Contínua vs. Discreta

Série contínua

$Z(t)$, com $t \in [0, T] \subset \mathbb{R}$.

Ex.: registro de marés.

Série discreta


y_t , com $t \in \mathbb{Z}$.

Ex.: PIB trimestral, IPCA mensal.

Como conseguimos mostrar uma série contínua na forma discreta, **este curso trabalhará majoritariamente com notação de séries **discretas**: y_t .**

Exemplo: Temperatura do Ar

Suponha que queiramos medir a temperatura do ar $Z(t)$, de dado local, durante 24 horas, em dois dias diferentes.



Duas trajetórias (dois dias diferentes de observação): curvas distintas do mesmo fenômeno físico.

Trajatória e Função Amostral

Cada curva observada no exemplo anterior, $Z^{(j)}(t)$, é uma trajetória do fenômeno – também chamada *função amostral*. Para t **fixo**, $Z(t)$ é uma **variável aleatória**, com sua própria distribuição de probabilidade.

No caso discreto: a j -ésima trajetória é $y_t^{(j)}$, $t \in \mathbb{Z}$; a série que observamos é uma única realização, $y_1, y_2, \dots, y_T$.

Quantas trajetórias é possível observar?

Oceanografia / Temperatura: várias trajetórias podem ser observadas experimentalmente.

Economia / Astronomia: em geral, só é possível observar **uma** trajetória – a própria série temporal que estudamos.

Uma série temporal analisada é, na realidade, apenas *parte* de uma trajetória.

Processo Estocástico vs. Série Temporal

Definição

Um processo estocástico é uma sequência de variáveis aleatórias $\{y_t, t \in \mathbb{Z}\}$ cujos valores são governados pelas leis da probabilidade.

Processo estocástico

O mecanismo gerador de dados: todas as trajetórias (realizações) possíveis.

Nunca observado diretamente.

Série temporal

Uma única realização (trajetória) desse processo: os dados que de fato coletamos.

O que aparece na planilha / banco de dados.

Processo Estocástico vs. Série Temporal: Exemplo

Exemplo

O IPCA de janeiro/2024 (0,42%) é **uma** realização do processo estocástico “inflação brasileira”. Poderíamos ter observado um valor diferente se o choque do petróleo em dezembro/2023 tivesse sido outro.

Objetivos da Análise de Séries Temporais

Obtida a série de dados, podemos estar interessados em:

- (a) investigar o **mecanismo gerador** da série;
- (b) fazer **previsões** de valores futuros (curto ou longo prazo);
- (c) **descrever** o comportamento da série (tendências, ciclos, sazonalidade);
- (d) procurar **periodicidades** relevantes (análise espectral).

Capítulo 1

Processos Estacionários

Econometria II · UFBA

Prof. Pablo Castro

O que vamos estudar neste capítulo?

Objetivo:

Construir as ferramentas para **descrever**,
testar e modelar processos estacionários.

Roteiro

1. Autocovariância e autocorrelação
2. Estacionariedade (fraca e estrita) e ergodicidade
3. Ruído branco
4. Processos $AR(1)$ e $AR(p)$
5. Processos $MA(q)$ e $ARMA(p,q)$
6. Exercícios

Onde estamos?

- ✓ Introdução ao MQO
- ✓ Regressão e inferência
- **Séries temporais**

Processos estacionários

Raiz unitária / ARIMA

Box-Jenkins

Cointegração / VAR

Autocovariância e Autocorrelação

Antes de falar em estacionariedade, precisamos de duas ferramentas: elas medem como os valores de um processo em instantes diferentes se relacionam entre si.

Definição – Função de autocovariância

Para um processo $\{y_t\}$ com $\mathbb{E}[y_t] = \mu_t$, a autocovariância de ordem k , no instante t , é


$$\gamma_{k,t} = \text{Cov}(y_t, y_{t-k}) = \mathbb{E}[(y_t - \mu_t)(y_{t-k} - \mu_{t-k})].$$

Definição – Função de autocorrelação

$$\rho_{k,t} = \frac{\gamma_{k,t}}{\gamma_{0,t}}, \quad \gamma_{0,t} = \text{Var}(y_t).$$

A autocorrelação é apenas a autocovariância normalizada, entre -1 e 1 .

Autocovariância e Autocorrelação – exemplo $k = 1$



$t = 1, 2$: ambos acima da média

$(y_1 - \mu) > 0$ e $(y_2 - \mu) > 0 \Rightarrow$ produto **positivo** $\Rightarrow$ contribui para $\gamma_1 > 0$: valores altos tendem a ser seguidos por valores altos (persistência).

$t = 2, 3$: um acima, outro abaixo

$(y_2 - \mu) > 0$ e $(y_3 - \mu) < 0 \Rightarrow$ produto **negativo** $\Rightarrow$ contribui para $\gamma_1 < 0$: valores altos tendem a ser seguidos por valores baixos (reversão).

γ_k é, em essência, a **média desses produtos** ao longo de toda a série.

Estacionariedade Fraca

Definição 1 – Processo fracamente estacionário

O processo $\{y_t\}$ é fracamente estacionário (ou estacionário de segunda ordem) se, para todo t :

1. $\mathbb{E}[y_t] = \mu < \infty$ (a média **não** depende de t)
2. $\text{Var}(y_t) = \gamma_0 < \infty$ (a variância **não** depende de t)
3. $\text{Cov}(y_t, y_{t-k}) = \gamma_k$ (a autocovariância depende *apenas* de k)

Ou seja, retomando a notação do slide anterior, estacionariedade fraca significa que o índice t pode ser **eliminado** de $\gamma_{k,t}$ e de $\rho_{k,t}$, escrevemos simplesmente γ_k e ρ_k .

Estacionário – exemplos

Taxa de inflação (IPCA): oscila em torno de uma média, sem tendência sistemática de crescimento.

Retorno de ações (log-retorno): média próxima de zero, variância relativamente estável.

Não-estacionário – exemplos

Nível do PIB: cresce ao longo do tempo – a média muda.

Preço de ações: apresenta tendência e variância crescente. **Taxa de câmbio nominal**: persistente, com choques permanentes.

Definição 2 – Processo estritamente estacionário

O processo $\{y_t\}$ é estritamente estacionário se a distribuição conjunta de $(y_{t_1}, \dots, y_{t_n})$ é igual à de $(y_{t_1+h}, \dots, y_{t_n+h})$, para qualquer h e qualquer conjunto de instantes $t_1, \dots, t_n$.

Diferença: a estacionariedade estrita exige que *toda* a distribuição do processo seja invariante no tempo; a fraca exige isso apenas dos dois primeiros momentos (média, variância, autocovariância).

- Estacionariedade estrita **não implica** a fraca.
- Estacionariedade fraca **não implica** a estrita.
- Se o processo for **gaussiano (distribuição normal)**, as duas noções coincidem.

Na prática, e ao longo deste curso, “estacionariedade” sempre vai significar estacionariedade **fraca**, a menos que dito o contrário.

Na prática, só observamos **uma** realização do processo estocástico. Isso levanta um problema: como estimar μ e γ_k a partir de uma única série?

Ideia

Em vez de calcular a média *entre* várias realizações (que não temos), calculamos a média *ao longo do tempo*, dentro da única realização observada:

$$\bar{y} = \frac{1}{T} \sum_{t=1}^T y_t.$$

Se $\bar{y}$ converge para $\mathbb{E}[y_t] = \mu$ quando $T \rightarrow \infty$, dizemos que o processo é ergódico para a média.

Lembre do exemplo da maré, na Introdução: cada dia de registro é uma trajetória diferente do mesmo processo, $Z^{(j)}(t)$.

Se tivéssemos, digamos, 50 dias de registro...

Poderíamos fixar um instante, por exemplo $t = 15h$, e olhar o valor da maré **naquele mesmo instante**, em cada um dos 50 dias:

$$Z^{(1)}(15), Z^{(2)}(15), \dots, Z^{(50)}(15).$$

A média **entre** essas 50 observações estimaria $\mathbb{E}[y_t]$ com $t = 15h$, que é a própria definição de esperança: a média sobre o espaço amostral, para um t fixo.

Ergodicidade: uma trajetória

Em Economia, não existem “50 Brasis paralelos” para comparar: não é possível observar o IPCA de janeiro de 2024 em 50 histórias diferentes e tirar a média entre elas.

Existe apenas **uma** série histórica do IPCA, que foi, de fato, observada.

Como estimar $\mathbb{E}[y_t]$? em vez da média entre trajetórias (que não temos), usamos a média *ao longo do tempo*, dentro da única trajetória observada (ergodicidade).

$$\bar{y} = \frac{1}{T} \sum_{t=1}^T y_t.$$

Condição suficiente

Um processo fracamente estacionário é ergódico para a média se $\sum_{k=0}^{\infty} |\gamma_k| < \infty$, isto é, se a dependência entre observações distantes no tempo desaparece rápido o suficiente.

Intuição: se γ_k não vai a zero (ou vai muito devagar) a medida que k cresce, observações muito distantes no tempo continuam fortemente correlacionadas. É como se a série se comportasse, na prática, como se tivesse “poucas” observações realmente independentes, mesmo com T grande. Nesse caso, a média ao longo do tempo deixa de ser um bom substituto para a média entre trajetórias.

Definição 3 – Ruído Branco (ou Ruído Branco Fraco)

O processo $\{\varepsilon_t\}$ é um ruído branco se:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0 \quad \forall k \neq 0$$

Quando $\varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$: **ruído branco gaussiano**.

O que significa “iid”? ε_t independente e identicamente distribuído: todo ε_t segue a mesma distribuição, e ε_t não depende de forma alguma (nem linear, nem não-linear) dos demais ε_s , $s \neq t$. É uma condição **mais forte** do que ruído branco: este exige apenas $\text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$ (ausência de correlação); iid exige ausência de *qualquer* dependência.

Intuição

Cada observação é uma “nova informação pura”: não carrega informação sobre o passado nem sobre o futuro.

Exemplo

Se a taxa de câmbio for um ruído branco, nenhum operador de câmbio conseguiria lucro sistemático olhando o histórico.

Processo AR(1)

Definição

$$y_t = c + \phi_1 y_{t-1} + u_t, \quad u_t \sim \text{RB}(0, \sigma^2)$$

É chamado autorregressivo porque y_t é explicado por sua própria defasagem, y_{t-1} .

Intuição: ϕ_1 mede quanto do desvio de y_{t-1} em relação à média “persiste” em y_t . Se ϕ_1 é grande (próximo de 1), choques são duradouros; se é pequeno, dissipam-se rápido.

Condição de estacionariedade

O AR(1) é **fracamente estacionário** se, e somente se, $|\phi_1| < 1$.

Processo AR(1): calculando a média

Sob $|\phi_1| < 1$, o processo é estacionário, logo $\mathbb{E}[y_t] = \mathbb{E}[y_{t-1}] = \mu$ (a média não muda com t). Tomando esperança dos dois lados de $y_t = c + \phi_1 y_{t-1} + u_t$:

$$\mathbb{E}[y_t] = c + \phi_1 \mathbb{E}[y_{t-1}] + \mathbb{E}[u_t] \quad \implies \quad \mu = c + \phi_1 \mu + 0$$

Isolando μ :

$$\mu(1 - \phi_1) = c \quad \implies \quad \boxed{\mathbb{E}[y_t] = \mu = \frac{c}{1 - \phi_1}}$$

Processo AR(1): calculando a média

Sob $|\phi_1| < 1$, o processo é estacionário, logo $\mathbb{E}[y_t] = \mathbb{E}[y_{t-1}] = \mu$ (a média não muda com t). Tomando esperança dos dois lados de $y_t = c + \phi_1 y_{t-1} + u_t$:

$$\mathbb{E}[y_t] = c + \phi_1 \mathbb{E}[y_{t-1}] + \mathbb{E}[u_t] \quad \implies \quad \mu = c + \phi_1 \mu + 0$$

Isolando μ :

$$\mu(1 - \phi_1) = c \quad \implies \quad \boxed{\mathbb{E}[y_t] = \mu = \frac{c}{1 - \phi_1}}$$

Para um AR(1) estacionário, precisamos de $|\phi_1| \neq 1$: se $\phi_1 = 1$, a divisão por $1 - \phi_1$ não existe e a média deixa de estar bem definida.

Processo AR(1): calculando a variância

Aplicando o operador $\text{Var}(\cdot)$:

$$\text{Var}(y_t) = \phi_1^2 \text{Var}(y_{t-1}) + \text{Var}(u_t) + 2\phi_1 \text{Cov}(y_{t-1}, u_t)$$

- $\text{Cov}(y_{t-1}, u_t) = 0$: y_{t-1} depende só de choques até $t - 1$; u_t é o choque **novo** em t .
- Estacionariedade $\Rightarrow \text{Var}(y_t) = \text{Var}(y_{t-1}) = \gamma_0$.

Logo $\gamma_0 = \phi_1^2 \gamma_0 + \sigma^2$, ou seja $\gamma_0(1 - \phi_1^2) = \sigma^2$:

$$\text{Var}(y_t) = \gamma_0 = \frac{\sigma^2}{1 - \phi_1^2}$$

Processo AR(1): calculando a variância

Aplicando o operador $\text{Var}(\cdot)$:

$$\text{Var}(y_t) = \phi_1^2 \text{Var}(y_{t-1}) + \text{Var}(u_t) + 2\phi_1 \text{Cov}(y_{t-1}, u_t)$$

- $\text{Cov}(y_{t-1}, u_t) = 0$: y_{t-1} depende só de choques até $t - 1$; u_t é o choque **novo** em t .
- Estacionariedade $\Rightarrow \text{Var}(y_t) = \text{Var}(y_{t-1}) = \gamma_0$.

Logo $\gamma_0 = \phi_1^2 \gamma_0 + \sigma^2$, ou seja $\gamma_0(1 - \phi_1^2) = \sigma^2$:

$$\boxed{\text{Var}(y_t) = \gamma_0 = \frac{\sigma^2}{1 - \phi_1^2}}$$

Para um AR(1) estacionário, precisamos de $|\phi_1| < 1$ (e não apenas $\neq 1$): se $|\phi_1| \geq 1$, o denominador é zero ou negativo, e a variância explode ou perde sentido.

Processo AR(1): calculando $\gamma_1 = \text{Cov}(y_t, y_{t-1})$

Passo 1. Substituir $y_t = c + \phi_1 y_{t-1} + u_t$ dentro da covariância:

$$\gamma_1 = \text{Cov}(y_t, y_{t-1}) = \text{Cov}(c + \phi_1 y_{t-1} + u_t, y_{t-1})$$

Passo 2. Usar as propriedades da covariância: uma constante não covaria com nada, e ela é linear na soma:

$$\gamma_1 = \underbrace{\text{Cov}(c, y_{t-1})}_{=0} + \phi_1 \text{Cov}(y_{t-1}, y_{t-1}) + \text{Cov}(u_t, y_{t-1})$$

Passo 3. Reconhecer que $\text{Cov}(y_{t-1}, y_{t-1}) = \text{Var}(y_{t-1}) = \gamma_0$, e que $\text{Cov}(u_t, y_{t-1}) = 0$ (pois u_t é o choque **novo** em t , independente de y_{t-1} , que só depende de choques até $t - 1$):

$$\gamma_1 = \phi_1 \gamma_0$$

Ou seja, a autocovariância de ordem 1 é apenas ϕ_1 vezes a variância.

Processo AR(1): generalizando γ_k e obtendo a ACF

Repetindo o mesmo argumento para γ_2 :

$$\gamma_2 = \text{Cov}(y_t, y_{t-2}) = \text{Cov}(c + \phi_1 y_{t-1} + u_t, y_{t-2}) = \phi_1 \text{Cov}(y_{t-1}, y_{t-2}) = \phi_1 \gamma_1$$

Logo, $\gamma_2 = \phi_1 \cdot \phi_1 \gamma_0 = \phi_1^2 \gamma_0$.

Por indução:

$$\gamma_k = \phi_1^k \gamma_0$$

Dividindo por γ_0 , obtemos a autocorrelação do AR(1):

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi_1^k$$

Exemplo

Inflação mensal: se a inflação de janeiro foi alta, a de fevereiro tende a ser também (inércia inflacionária). $\phi_1 = 0.5$: metade do desvio do mês passado persiste hoje; a autocorrelação decai geometricamente, $\rho_k = 0,5^k$.

Processo AR(p)

Generalizando o AR(1), o processo autorregressivo de ordem p é:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + u_t, \quad u_t \sim \text{RB}(0, \sigma^2)$$

Agora y_t depende das suas últimas p defasagens, não só da anterior.

Assim como fizemos para o AR(1), podemos reescrever as defasagens de uma série temporal y_t de forma mais compacta usando o operador defasagem (*lag operator*).

Operador Lag (L)

O operador L atua sobre uma série deslocando-a um período para trás:

$$L y_t = y_{t-1}, \quad L^i y_t = y_{t-i}$$

Por exemplo, $L^2 y_t = y_{t-2}$ e $L^p y_t = y_{t-p}$.

Processo $AR(p)$ com o Operador Lag

Reescrevendo cada defasagem y_{t-i} como $L^i y_t$:

$$y_t = c + \phi_1 L y_t + \phi_2 L^2 y_t + \cdots + \phi_p L^p y_t + u_t$$

Passo 1. Jogar todos os termos com y_t para o lado esquerdo:

$$y_t - \phi_1 L y_t - \phi_2 L^2 y_t - \cdots - \phi_p L^p y_t = c + u_t$$

Passo 2. Colocar y_t em evidência:

$$(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p) y_t = c + u_t$$

Passo 3. Chamar o polinômio entre parênteses de $\Phi(L)$:

$$\underbrace{(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p)}_{\Phi(L)} y_t = c + u_t \quad \implies \quad \Phi(L) y_t = c + u_t$$

em que $\Phi(L)$ é o **polinômio característico** do $AR(p)$.

Condição de Estacionariedade – $AR(p)$

O processo é fracamente estacionário se, e somente se, as raízes do polinômio característico $\Phi(z) = 0$ estiverem **fora do círculo unitário**, $|z| > 1$ (equivalentemente, os *inversos* das raízes devem estar *dentro* do círculo).

Caso particular: para $p = 1$, $\Phi(z) = 1 - \phi_1 z$, cuja raiz é $z = 1/\phi_1$. A condição $|z| > 1$ vira $|1/\phi_1| > 1$, ou seja, $|\phi_1| < 1$: a condição já vista para o $AR(1)$.

Exemplo: AR(2) para o crescimento do PIB

Verificando a estacionariedade

$$y_t = 0.4 y_{t-1} + 0.2 y_{t-2} + u_t$$

Polinômio característico: $\Phi(z) = 1 - 0.4z - 0.2z^2$.

Resolvendo $\Phi(z) = 0$, as raízes ficam fora do círculo unitário $\Rightarrow$ o processo é **estacionário**.

Interpretação: o crescimento do PIB neste trimestre depende dos dois trimestres anteriores.

Processo $AR(p)$: Generalizando a Média

Exatamente como fizemos no $AR(1)$, tomando esperança dos dois lados da equação original (com $\mathbb{E}[y_t] = \mu$ para todo t , sob estacionariedade):

$$\mu = c + \phi_1\mu + \cdots + \phi_p\mu \quad \implies$$

$$\mathbb{E}[y_t] = \mu = \frac{c}{1 - \phi_1 - \cdots - \phi_p}$$

E a variância e as autocovariâncias?

Podem ser obtidas multiplicando por $y_{t-k} - \mu$ e tomando esperança, o que gera um sistema de equações – as **equações de Yule-Walker** – que estudaremos em detalhe mais adiante.

$$y_t = \mu + u_t + \theta_1 u_{t-1}, \quad u_t \sim \text{RB}(0, \sigma^2)$$

Propriedade

O processo MA(1) é **sempre fracamente estacionário**, pois é uma combinação linear finita de um ruído branco.

Processo MA(1): calculando os momentos

Como u_t é ruído branco, $\mathbb{E}[u_t] = 0$, $\text{Var}(u_t) = \sigma^2$ e $\text{Cov}(u_t, u_{t-j}) = 0$ para $j \neq 0$. Aplicando isso a $y_t = \mu + u_t + \theta_1 u_{t-1}$:

$$\mathbb{E}[y_t] = \mu + \mathbb{E}[u_t] + \theta_1 \mathbb{E}[u_{t-1}] = \mu$$

$$\gamma_0 = \text{Var}(y_t) = \text{Var}(u_t) + \theta_1^2 \text{Var}(u_{t-1}) + 2\theta_1 \underbrace{\text{Cov}(u_t, u_{t-1})}_{=0} = (1 + \theta_1^2)\sigma^2$$

$$\gamma_1 = \text{Cov}(y_t, y_{t-1}) = \text{Cov}(u_t + \theta_1 u_{t-1}, u_{t-1} + \theta_1 u_{t-2}) = \theta_1 \text{Var}(u_{t-1}) = \theta_1 \sigma^2$$

Para $k \geq 2$, y_t e y_{t-k} não compartilham nenhum choque u em comum $\Rightarrow \gamma_k = 0$.

Resultado

$$\mathbb{E}[y_t] = \mu, \quad \text{Var}(y_t) = (1 + \theta_1^2)\sigma^2, \quad \gamma_k = \begin{cases} \theta_1 \sigma^2 & k = 1 \\ 0 & k > 1 \end{cases}$$

Propriedades

$$\mathbb{E}[y_t] = \mu$$

Variância: $\gamma_0 = \text{Var}(y_t) = (1 + \theta_1^2) \sigma^2$

Autocovariância: $\gamma_k = \text{Cov}(y_t, y_{t-k}) = \begin{cases} \theta_1 \sigma^2 & k = 1 \\ 0 & k > 1 \end{cases}$

Autocorrelação: $\rho_k = \begin{cases} \frac{\theta_1}{1 + \theta_1^2} & k = 1 \\ 0 & k > 1 \end{cases}$

Exemplo

Erros de previsão do orçamento público: um choque inesperado na arrecadação afeta a previsão deste mês e ainda aparece no mês seguinte, mas depois desaparece.

Intuição: no MA(1), o efeito do choque dura apenas um período – memória curta.

$$y_t = \mu + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \cdots + \theta_q u_{t-q}$$

Todo processo MA(q) é **sempre fracamente estacionário**, pois é uma combinação linear finita de ruídos brancos contemporâneos e passados.

Propriedades gerais

$$\mathbb{E}[y_t] = \mu$$

Variância: $\text{Var}(y_t) = (1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2) \sigma^2$

Autocovariância:
$$\gamma_k = \begin{cases} (\theta_k + \theta_{k+1}\theta_1 + \theta_{k+2}\theta_2 + \cdots + \theta_q\theta_{q-k}) \sigma^2 & k \leq q \\ 0 & k > q \end{cases}$$

Autocorrelação:
$$\rho_k = \frac{\gamma_k}{\gamma_0} = \begin{cases} \frac{\theta_k + \theta_{k+1}\theta_1 + \cdots + \theta_q\theta_{q-k}}{1 + \theta_1^2 + \cdots + \theta_q^2} & k \leq q \\ 0 & k > q \end{cases}$$

Processo MA(q): de onde vem a fórmula de γ_k

A mesma ideia do MA(1) se aplica: $\gamma_k = \text{Cov}(y_t, y_{t-k})$ só recebe contribuição dos choques u que aparecem **nos dois** termos, y_t e y_{t-k} .

Exemplo com $q = 2$, $k = 1$: $y_t = \mu + u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2}$ e $y_{t-1} = \mu + u_{t-1} + \theta_1 u_{t-2} + \theta_2 u_{t-3}$ compartilham u_{t-1} (coeficientes θ_1 e 1) e u_{t-2} (coeficientes θ_2 e θ_1):

$$\gamma_1 = \theta_1 \cdot 1 \cdot \sigma^2 + \theta_2 \cdot \theta_1 \cdot \sigma^2 = (\theta_1 + \theta_2 \theta_1) \sigma^2,$$

que é exatamente a fórmula geral $\gamma_k = (\theta_k + \theta_{k+1} \theta_1 + \dots) \sigma^2$ avaliada em $k = 1$. Para $k > q$, os dois termos não compartilham nenhum choque, logo $\gamma_k = 0$.

Processo ARMA(p, q)

$$y_t = c + \underbrace{\phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p}}_{\text{componente AR}} + \underbrace{u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \cdots + \theta_q u_{t-q}}_{\text{componente MA}}$$

Combina memória de **valores passados** (AR) com memória de **choques passados** (MA).

Estacionariedade

Determinada **somente pelo componente AR**: as raízes de $\Phi(z) = 0$ devem estar fora do círculo unitário. O componente MA não impõe restrições adicionais.

Exemplo

IPCA acumulado em 12 meses: combina inércia inflacionária do passado (AR) com resposta a choques de energia e câmbio (MA).

Propriedade: um processo $AR(1)$ pode ser escrito como um $MA(\infty)$

Considere um $AR(1)$ **estacionário** ($|\phi_1| < 1$) com $u_t \sim RB(0, \sigma^2)$:

$$y_t = c + \phi_1 y_{t-1} + u_t$$

Ideia: substituir y_{t-1} pela sua própria definição, depois y_{t-2} , e assim por diante.

Substituição recursiva

$$\begin{aligned} y_t &= c + \phi_1 \underbrace{(c + \phi_1 y_{t-2} + u_{t-1})}_{y_{t-1}} + u_t \\ &= c(1 + \phi_1) + \phi_1^2 y_{t-2} + u_t + \phi_1 u_{t-1} \end{aligned}$$

Substituindo agora $y_{t-2} = c + \phi_1 y_{t-3} + u_{t-2}$:

$$y_t = c(1 + \phi_1 + \phi_1^2) + \phi_1^3 y_{t-3} + u_t + \phi_1 u_{t-1} + \phi_1^2 u_{t-2}$$

Propriedade: um processo $AR(1)$ pode ser escrito como um $MA(\infty)$

Repetindo o procedimento n vezes, obtemos uma expressão com três blocos: a constante acumulada, o termo que sobra com y_{t-n} , e a soma dos choques passados.

Após n substituições – escrevendo termo a termo:

$$\begin{aligned} y_t &= c \left(1 + \phi_1 + \phi_1^2 + \cdots + \phi_1^{n-1} \right) + \phi_1^n y_{t-n} \\ &+ u_t + \phi_1 u_{t-1} + \phi_1^2 u_{t-2} + \cdots + \phi_1^{n-1} u_{t-(n-1)} \end{aligned}$$

A mesma expressão, agora em notação compacta:

$$y_t = c \sum_{i=0}^{n-1} \phi_1^i + \phi_1^n y_{t-n} + \sum_{i=0}^{n-1} \phi_1^i u_{t-i}$$

AR(1) como MA(∞) – tomando o limite

Partindo da expressão obtida após n substituições:

$$y_t = c \sum_{i=0}^{n-1} \phi_1^i + \phi_1^n y_{t-n} + \sum_{i=0}^{n-1} \phi_1^i u_{t-i}$$

Sob a hipótese de estacionariedade $|\phi_1| < 1$, fazendo $n \rightarrow \infty$:

- $\sum_{i=0}^{n-1} \phi_1^i \longrightarrow \frac{1}{1 - \phi_1}$ (soma da PG infinita)
- $\phi_1^n y_{t-n} \longrightarrow 0$ (em média quadrática, pois $|\phi_1|^n \rightarrow 0$)
- $\sum_{i=0}^{n-1} \phi_1^i u_{t-i} \longrightarrow \sum_{i=0}^{\infty} \phi_1^i u_{t-i}$

AR(1) como MA(∞)

Resultado: AR(1) = MA(∞)

$$y_t = \underbrace{\frac{c}{1 - \phi_1}}_{\mu} + \sum_{i=0}^{\infty} \phi_1^i u_{t-i}$$

Ou seja, o AR(1) tem a forma de um MA(∞) com média $\mu = c/(1 - \phi_1)$ e coeficientes $\theta_i = \phi_1^i$, que **decaem geometricamente** em i .

Demonstração *alternativa* via operador lag

Reescrevendo o AR(1) com o operador L :

$$y_t - \phi_1 L y_t = c + u_t \iff (1 - \phi_1 L) y_t = c + u_t$$

Sob $|\phi_1| < 1$, o polinômio $1 - \phi_1 L$ é invertível e

$$(1 - \phi_1 L)^{-1} = \sum_{i=0}^{\infty} \phi_1^i L^i,$$

em analogia à série geométrica $\frac{1}{1-x} = \sum_{i=0}^{\infty} x^i$ válida para $|x| < 1$.

Aplicando $(1 - \phi_1 L)^{-1}$ dos dois lados:

$$y_t = (1 - \phi_1 L)^{-1}(c + u_t) = \frac{c}{1 - \phi_1} + \sum_{i=0}^{\infty} \phi_1^i u_{t-i}$$

– mesmo resultado obtido pela substituição recursiva. ■

Interpretação econômica

Cada choque u_{t-i} continua afetando y_t , mas com peso ϕ_1^i que diminui geometricamente. Quanto maior ϕ_1 (mais perto de 1), **mais persistente** é o efeito de choques antigos sobre o presente.

Enunciado

Considere o processo $X_t = Y_t + 0,5 Y_{t-1} - 0,2 Y_{t-2}$, em que Y_t é ruído branco com $\mathbb{E}[Y_t] = 0$, $\text{Var}(Y_t) = \sigma^2$ e $\mathbb{E}[Y_t Y_s] = 0$ para $t \neq s$.

Julgue as afirmativas como **Verdadeiro (V)** ou **Falso (F)**:

- (a) $\mathbb{E}[X_t] = 0$
- (b) $\text{Var}(X_t) = 1,29 \sigma^2$
- (c) $\text{Cov}(X_t, X_{t-1}) = 0,4 \sigma^2$
- (d) $\text{Cov}(X_t, X_{t-2}) = 0$
- (e) $\text{Cov}(X_t, X_{t-3}) = 0$

X_t é MA(2) com $\theta_1 = 0,5$ e $\theta_2 = -0,2$.

- (a) V $\mathbb{E}[X_t] =$
 $\mathbb{E}[Y_t] + 0,5 \mathbb{E}[Y_{t-1}] - 0,2 \mathbb{E}[Y_{t-2}] = 0$
- (b) V $\text{Var}(X_t) = (1 + 0,5^2 + 0,2^2) \sigma^2 = 1,29 \sigma^2$
- (c) V $\text{Cov}(X_t, X_{t-1}) = (\theta_1 + \theta_1 \theta_2) \sigma^2$
 $= (0,5 + 0,5 \cdot (-0,2)) \sigma^2 = 0,4 \sigma^2$
- (d) F $\text{Cov}(X_t, X_{t-2}) = \theta_2 \sigma^2 = -0,2 \sigma^2 \neq 0$
- (e) V MA(2): autocovariância é zero para lags
 $k > q = 2$.

Fórmula geral MA(q)

$$\gamma_k = \begin{cases} \left(\sum_{j=0}^{q-k} \theta_j \theta_{j+k} \right) \sigma^2 & k \leq q \\ 0 & k > q \end{cases}$$

com $\theta_0 = 1$.

Enunciado

Considere o processo $Y_t = 5 + e_t + 0,3 e_{t-1}$, em que e_t é ruído branco com $\mathbb{E}[e_t] = 0$, $\text{Var}(e_t) = \sigma^2$ e $\mathbb{E}[e_t e_s] = 0$ para $t \neq s$.

Julgue as afirmativas como **V** ou **F**:

- (a) $\mathbb{E}[Y_t] = 5$
- (b) $\text{Var}(Y_t) = \sigma^2$
- (c) $\text{Cov}(Y_t, Y_{t-1}) = \frac{3\sigma^2}{10}$
- (d) $\text{Cov}(Y_t, Y_{t-3}) = 0$
- (e) $\text{Corr}(Y_t, Y_{t-1}) = \frac{1}{4}$

Y_t é MA(1) com média 5 e $\theta_1 = 0,3$.

(a) V $\mathbb{E}[Y_t] = 5 + \mathbb{E}[e_t] + 0,3 \mathbb{E}[e_{t-1}] = 5$

(b) F $\text{Var}(Y_t) = (1 + 0,3^2)\sigma^2 = 1,09 \sigma^2$

(c) V $\gamma_1 = \theta_1 \sigma^2 = 0,3 \sigma^2 = \frac{3\sigma^2}{10} \checkmark$

(d) V MA(1): $\gamma_k = 0$ para $k > 1$, portanto $\gamma_3 = 0$.

(e) F $\rho_1 = \frac{0,3}{1,09} \approx 0,275 \neq \frac{1}{4}$

Resumo MA(1)

$$\text{Var} = (1 + \theta_1^2)\sigma^2$$

$$\rho_1 = \frac{\theta_1}{1 + \theta_1^2}$$

$$\rho_k = 0, \quad k > 1$$

Atenção (b): confusão comum –

$\text{Var}(Y_t) \neq \sigma^2$ sempre que $\theta_1 \neq 0$.

Enunciado

Considere o modelo AR(1):

$$Y_t = \phi_1 Y_{t-1} + u_t, \quad |\phi_1| < 1, \quad u_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_u^2)$$

Julgue as afirmativas como **V** ou **F**:

- (a) Y_t pode ser representado como $Y_t = \sum_{i=0}^{\infty} \phi_1^i u_{t-i}$
- (b) $\mathbb{E}[Y_t] = 0$
- (c) $\text{Var}(Y_t) = \sigma_u^2$
- (d) Y_t tem distribuição normal
- (e) $\text{Cov}(Y_{t-1}, Y_{t-2}) = \phi_1^2 \sigma_u^2$

(a) V Substituições recursivas:

$$Y_t = u_t + \phi_1 Y_{t-1} = u_t + \phi_1 u_{t-1} + \phi_1^2 Y_{t-2} = \dots$$

Sob $|\phi_1| < 1$ a série converge.

(b) V $\mathbb{E}[Y_t] = \sum_{i=0}^{\infty} \phi_1^i \mathbb{E}[u_{t-i}] = 0$ (constante $c = 0$ no modelo)

(c) F $\text{Var}(Y_t) = \frac{\sigma_u^2}{1 - \phi_1^2} \neq \sigma_u^2$ (exceto se $\phi_1 = 0$)

(d) V Y_t é combinação linear infinita de normais iid $\Rightarrow$ normal.

(e) F $\text{Cov}(Y_{t-1}, Y_{t-2}) = \phi_1 \text{Var}(Y_t) = \frac{\phi_1 \sigma_u^2}{1 - \phi_1^2}$

A alternativa diz $\phi_1^2 \sigma_u^2$, que estaria errada.

Resumo AR(1) estacionário

$$\mathbb{E}[Y_t] = \frac{c}{1 - \phi_1}$$

$$\text{Var}(Y_t) = \frac{\sigma_u^2}{1 - \phi_1^2}$$

$$\gamma_k = \phi_1^k \cdot \text{Var}(Y_t)$$

$$\rho_k = \phi_1^k$$

Resumo da aula

Conceitos revisados

- Processo estocástico vs. série temporal
- Estacionariedade fraca (3 condições)
- Ruído branco
- $AR(1)$, $AR(p)$: condição das raízes
- $MA(1)$, $MA(q)$: sempre estacionário
- $ARMA(p,q)$: combinação de $AR(p)$ e $MA(q)$

Para a próxima aula

- Processos não-estacionários
- Passeio aleatório (*random walk*)
- Efeitos permanentes de choques
- Diferenciação e processo $I(1)$
- Teste ADF

Takeaway:

Num processo estacionário, choques são **temporários**.

Num não-estacionário, são **permanentes**.

Dúvidas?

Próxima aula: Processos Não Estacionários