

Capítulo 2

Processos Não Estacionários

Econometria II · UFBA

Prof. Pablo Castro

Parte I

- Tendência estacionária e estocástica
- Processos integrados $I(d)$
- Passeios aleatórios

Parte II

- Testes de raiz unitária: Dickey-Fuller
- Dickey-Fuller Aumentado
- Exercícios

Seção 2.1

Processos Não Estacionários e Processos Integrados

O que estudamos neste capítulo?

Objetivo:

Distinguir os tipos de não-estacionariedade e realizar testes para detectá-los.

Roteiro

1. Motivação
2. Tendência determinística vs. estocástica
3. Processos integrados $I(d)$
4. Passeio aleatório (*random walk*)
5. Testes de Dickey-Fuller e Dickey-Fuller Aumentado

Por que estacionariedade importa?

Pense em duas situações do dia a dia:

Situação 1

Você erra a mão no tempero de uma receita que já faz toda semana. Na próxima vez, você volta a fazer do jeito de sempre: o erro de hoje **não muda** a receita da semana que vem.

Situação 2

Você erra um depósito e credita R\$ 1.000 a mais na sua poupança. Esse erro **persiste**: todo saldo futuro conterà os R\$ 1.000 extra, a menos que alguém corrija.

Em uma série **estacionária** (Situação 1: o “erro” é temporário), e em uma série **não estacionária** (Situação 2: o “erro” é permanente).

Por que precisamos tratar a não-estacionariedade

Quando uma série temporal não é estacionária, é impossível estimar todos os seus momentos, e portanto, impossível fazer estimação e inferência estatística da forma usual.

Lembre a variância não condicional de um AR(1) visto na Aula 1:

$$\text{Var}(y_t) = \frac{\sigma^2}{1 - \phi^2}.$$

Se $\phi = 1$ a variância explode.

Séries Estacionárias vs. Não Estacionárias

Série estacionária

Oscila em torno de uma **média fixa**.

Choques têm efeito **temporário**.

A variância não cresce com o tempo.

O passado distante não importa.

Exemplo

Taxa de inflação: sobe, desce, mas gravita em torno de uma média histórica.

Série não estacionária

Sem média fixa para onde retornar.

Choques têm efeito **permanente**.


A variância **cresce** com o tempo.

O passado inteiro se acumula no presente.

Exemplo

Nível de preços: nunca “volta” a um patamar anterior: cada choque desloca o índice de forma permanente.

Exemplo: IPCA



Fonte: IBGE/SIDRA — Série 1737 (IPCA). 2010-2023.

Séries Estacionárias vs. Não Estacionárias

Consequência

Se a série for não estacionária e isso não for tratado, os modelos produzirão **inferências inválidas** e **previsões enganosas**. Verificar a estacionariedade é o **primeiro passo** de qualquer análise de séries temporais.

Decompondo uma série

De forma geral, uma série econômica pode ser decomposta em três partes:

$$y_t = \underbrace{\text{tendência}}_{\text{determinística}} + \underbrace{\text{componente estacionário}}_{\psi(L)\varepsilon_t} + \text{ruído}.$$

O que diferencia os modelos que veremos a seguir é **onde está localizada a não estacionariedade**: ela pode estar na tendência determinística, ou pode estar **incorporada aos próprios choques** que se acumulam ao longo do tempo.

Cada tipo de não-estacionariedade possui um tratamento diferente.

Como Reconhecer no Gráfico?

Visualmente:

Tendência determinística

A série sobe (ou desce) oscilando em torno de uma reta ou parábola **bem definida**.


Veremos na Aula 3.

Tendência estocástica


A série também sobe (ou desce), mas **não em torno de uma reta/parábola fixa**. Ela muda de patamar e **não retorna** ao patamar anterior: os desvios se acumulam e crescem com o tempo.

Exemplos

Tendência determinística



Tendência estocástica



Diferenciação e o Operador Δ

O operador diferença

O operador Δ aplicado a uma série y_t é definido como:

$$\Delta y_t = y_t - y_{t-1}$$

Diferenciar uma série significa tomar a diferença entre cada observação e a observação anterior. É possível aplicar o operador mais de uma vez:

Primeira diferença: $\Delta y_t = y_t - y_{t-1}$

Segunda diferença (aplicar Δ ao resultado anterior):

$$\Delta^2 y_t = \Delta(\Delta y_t) = \Delta(y_t - y_{t-1}) = \Delta y_t - \Delta y_{t-1} = (y_t - y_{t-1}) - (y_{t-1} - y_{t-2})$$

Definição


Dizemos que a **série não-estacionária** $\{y_t\}$ é **integrado de ordem d** , $y_t \sim I(d)$, se são necessárias d **diferenciações** para torná-lo estacionário:

$$\Delta^d y_t \sim I(0)$$

A notação $I(d)$ indica quantas vezes a série precisa ser diferenciada para se tornar estacionária.

- **$I(0)$** : já estacionário.
- **$I(1)$** : uma diferença torna a série estacionária: $\Delta y_t \sim I(0)$
- **$I(2)$** : duas diferenças são necessárias: $\Delta^2 y_t \sim I(0)$

Séries integradas são chamadas $\text{ARIMA}(p,d,q)$



- Quando a série **não** é estacionária, mas $\Delta^d y_t$ é um $\text{ARMA}(p,q)$, chamamos o processo original de $\text{ARIMA}(p,d,q)$: o “I” de *integrado* e o índice d marca a quantidade de diferenciações necessárias para tornar a série estacionária.

Classificando um ARIMA pela Equação

Considere o processo

$$y_t = 1,5 y_{t-1} - 0,5 y_{t-2} + \varepsilon_t + 0,4 \varepsilon_{t-1}.$$

À primeira vista, é um ARMA(2,1). Com o operador de defasagem:

$$(1 - 1,5L + 0,5L^2) y_t = (1 + 0,4L) \varepsilon_t.$$

O polinômio autorregressivo se fatora como $1 - 1,5L + 0,5L^2 = (1 - L)(1 - 0,5L)$. A raiz $L = 1$ é uma **raiz unitária**: o processo não é estacionário.

Isolando o fator $(1 - L) = \Delta$:

$$(1 - 0,5L) \underbrace{(1 - L) y_t}_{\Delta y_t} = (1 + 0,4L) \varepsilon_t \implies \Delta y_t = 0,5 \Delta y_{t-1} + \varepsilon_t + 0,4 \varepsilon_{t-1}.$$

Δy_t é um ARMA(1,1) estacionário ($|0,5| < 1$). Logo, y_t é um **ARIMA(1,1,1)**: $p = 1$ (parte AR de Δy_t), $d = 1$ (uma diferença), $q = 1$ (parte MA).

Exemplo Numérico

Suponha uma série de nível de preços hipotética com um choque em $t = 3$:

t	1	2	3	4	5	6
y_t (nível)	100	101	105	106	107	108
$\Delta y_t = y_t - y_{t-1}$	—	1	4	1	1	1

Repare: o **nível** y_t carrega o choque de $t = 3$ (subiu para 105 e nunca voltou a 101) — é uma série $I(1)$, não estacionária. A **diferença** Δy_t , depois do choque isolado em $t = 3$, volta a oscilar em torno de 1 — parece estacionária: é $I(0)$.

Seção 2.2

Passeio Aleatório

Definição

O **passeio aleatório** (*random walk*) é o AR(1) com $\phi_1 = 1$:

$$y_t = y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{RB}(0, \sigma^2), \quad \text{com } y_0 \text{ fixo}$$

Por que os choques se acumulam? Substituindo recursivamente:

$$y_1 = y_0 + \varepsilon_1$$

$$y_2 = y_1 + \varepsilon_2 = y_0 + \varepsilon_1 + \varepsilon_2$$

$$y_3 = y_2 + \varepsilon_3 = y_0 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3$$

$$\vdots$$

$$y_t = y_0 + \sum_{i=1}^t \varepsilon_i$$

Cada choque ε_i é incorporado de forma **permanente** no processo.

Intuição: o Bêbado Andando

Imagine um bêbado saindo de um poste (y_0). A cada passo, ele dá um passo aleatório para a frente ou para trás (ε_t).

Depois de t passos, ele está em

$$y_t = y_0 + \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t.$$

Pergunta: **onde ele vai estar daqui a 10 passos?** A melhor resposta possível é: **onde ele está agora**. Não há nenhuma informação que aponte para a esquerda ou para a direita. Os passos futuros são, em média, zero.

No passeio aleatório, a melhor previsão h passos à frente é sempre o valor da variável hoje.

Muitas séries financeiras (câmbio, ações) se comportam como passeios aleatórios.

Passeio Aleatório: Calculando a Esperança

Partimos do resultado já obtido por substituição recursiva:

$$y_t = y_0 + \sum_{i=1}^t \varepsilon_i$$

Aplicamos o operador esperança dos dois lados e usamos linearidade:

$$\mathbb{E}[y_t] = \mathbb{E}\left[y_0 + \sum_{i=1}^t \varepsilon_i\right] = \mathbb{E}[y_0] + \sum_{i=1}^t \mathbb{E}[\varepsilon_i]$$

$$\mathbb{E}[y_t] = y_0 + \underbrace{0 + 0 + \cdots + 0}_{t \text{ termos}} = y_0$$

Resultado: $\mathbb{E}[y_t] = y_0$ para todo t : a esperança não depende do tempo.

Passeio Aleatório: Calculando a Variância

Partimos do mesmo resultado, $y_t = y_0 + \sum_{i=1}^t \varepsilon_i$, e aplicamos o operador variância:

$$\text{Var}(y_t) = \text{Var}\left(y_0 + \sum_{i=1}^t \varepsilon_i\right)$$

y_0 é uma constante, então não contribui para a variância:

$$\text{Var}(y_t) = \text{Var}\left(\sum_{i=1}^t \varepsilon_i\right)$$

Como os ε_i são independentes entre si, a variância da soma é a soma das variâncias (todos os termos cruzados $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$, $i \neq j$):

$$\text{Var}(y_t) = \sum_{i=1}^t \text{Var}(\varepsilon_i) = \underbrace{\sigma^2 + \sigma^2 + \cdots + \sigma^2}_{t \text{ termos}} = t \sigma^2$$

Resultado: $\text{Var}(y_t) = t \sigma^2 \xrightarrow{t \rightarrow \infty} \infty$: a incerteza sobre y_t cresce sem limite.

Passeio Aleatório: Calculando a Covariância

Queremos $\text{Cov}(y_t, y_{t+s})$, com $s > 0$. Primeiro, escrevemos y_{t+s} em função de y_t :

$$y_{t+s} = y_0 + \sum_{i=1}^{t+s} \varepsilon_i = y_0 + \underbrace{\sum_{i=1}^t \varepsilon_i}_{y_t} + \sum_{i=t+1}^{t+s} \varepsilon_i = y_t + \sum_{i=t+1}^{t+s} \varepsilon_i$$

Aplicamos $\text{Cov}(y_t, \cdot)$ e usamos bilinearidade:

$$\text{Cov}(y_t, y_{t+s}) = \text{Cov}\left(y_t, y_t + \sum_{i=t+1}^{t+s} \varepsilon_i\right) = \underbrace{\text{Cov}(y_t, y_t)}_{\text{Var}(y_t)} + \text{Cov}\left(y_t, \sum_{i=t+1}^{t+s} \varepsilon_i\right)$$

y_t depende só de $\varepsilon_1, \dots, \varepsilon_t$, que são independentes de $\varepsilon_{t+1}, \dots, \varepsilon_{t+s}$. Logo o segundo termo é zero:

$$\text{Cov}(y_t, y_{t+s}) = \text{Var}(y_t) = t \sigma^2$$

O que derivamos

$$\mathbb{E}[y_t] = y_0$$

$$\text{Var}(y_t) = t \sigma^2 \xrightarrow{t \rightarrow \infty} \infty$$

$$\text{Cov}(y_t, y_{t+s}) = t \sigma^2, \quad s > 0$$

Comparação com AR(1) estacionário

No AR(1) com $|\phi| < 1$, cada choque é amortecido pelo fator $\phi^k \rightarrow 0$.

No passeio aleatório ($\phi = 1$), o fator de amortecimento é $1^k = 1$.

Passeio Aleatório: Violação da Estacionariedade

As três propriedades que acabamos de derivar mostram que o passeio aleatório viola as condições de estacionariedade.

Condição	Exige	Passeio aleatório
1. Média	$\mathbb{E}[y_t] = \mu$ constante	$\mathbb{E}[y_t] = y_0$ ✓*
2. Variância	$\text{Var}(y_t) < \infty$	$t\sigma^2 \rightarrow \infty$ viola
3. Covariância	Cov só de k	$t\sigma^2$: depende de t viola

*Para o passeio aleatório *puro* a média é constante em y_0 , mas as condições 2 e 3 são violadas.

Cada choque é absorvido permanentemente, e a variância cresce sem limite com t , ainda que a média seja constante e igual a y_0 .

Passeio Aleatório com Drift

Definição

$$y_t = c + y_{t-1} + \varepsilon_t, \quad \text{com } y_0 \text{ fixo}$$

Iteração: Substituindo recursivamente:

$$y_1 = c + y_0 + \varepsilon_1$$

$$y_2 = c + y_1 + \varepsilon_2 = 2c + y_0 + \varepsilon_1 + \varepsilon_2$$

$$y_3 = c + y_2 + \varepsilon_3 = 3c + y_0 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3$$

$$\vdots$$

$$y_t = y_0 + ct + \sum_{i=1}^t \varepsilon_i$$

O c aparece **uma vez por período** — após t períodos acumula ct .

Propriedades

$$\mathbb{E}[y_t] = y_0 + ct \quad \longrightarrow \text{cresce com } t$$

$$\text{Var}(y_t) = t \sigma^2$$

A série combina uma tendência determinística (ct ; ver Capítulo 3) com a **tendência estocástica** ($\sum \varepsilon_i$).

Com $c \neq 0$, as **três condições** de estacionariedade são violadas.

Ao diferenciar: $\Delta y_t = c + \varepsilon_t$ — **estacionário**.

Exemplo

PIB real brasileiro: cresce de forma persistente ($c > 0$), com desvios acumulados.

Crises como 2015–16 e 2020 reduzem o nível do PIB de forma permanente: o produto não recupera o patamar anterior.

c é o drift: desloca a série para cima a cada período.

$\sum \varepsilon_i$ é a tendência estocástica: acumula os choques.

Seção 2.3

Teste de Dickey-Fuller

Relembrando: a Lógica de um Teste de Hipótese

Um teste de hipótese em MQO segue sempre os mesmos passos, os mesmos que você já usou para testar se um coeficiente é zero:

1. Formule H_0 : uma afirmação específica sobre um parâmetro.
2. Calcule uma estatística de teste: (estimativa – valor sob H_0) dividido pelo erro-padrão.
3. Compare com um valor crítico, retirado de uma distribuição de referência.
4. Decida: se a estatística for extrema demais para ser explicada por acaso, rejeite H_0 .

O teste de Dickey-Fuller segue esses mesmos passos. A diferença aparece no passo 3: a distribuição de referência não é a t de Student, pelo motivo discutido a seguir.

A inspeção visual de uma série raramente permite classificá-la como de tendência estocástica ou determinística. Por isso foram desenvolvidos testes formais para verificar a existência de raízes unitárias – o primeiro deles por Dickey e Fuller (1979, 1981).

Considere o modelo $y_t = \phi y_{t-1} + \varepsilon_t$. A tendência natural seria estimar esse modelo e testar $H_0: \phi = 1$ com um teste t convencional. Como os pacotes econométricos reportam testes contra a nula de coeficiente igual a zero, faz-se a seguinte manipulação algébrica:

Hipóteses e Reformulação do Teste

Subtrai-se y_{t-1} de ambos os lados:

$$\underbrace{y_t - y_{t-1}}_{\Delta y_t} = \phi_1 y_{t-1} - y_{t-1} + \varepsilon_t$$

$$\Delta y_t = (\phi_1 - 1) y_{t-1} + \varepsilon_t, \quad \alpha = \phi_1 - 1$$

$$\boxed{\Delta y_t = \alpha y_{t-1} + \varepsilon_t}$$

Dessa forma, $H_0: \phi = 1$ é equivalente a $H_0: \alpha = 0$, contra $H_1: \alpha < 0$.

Teste **unicaudal à esquerda**: rejeitamos H_0 quando $\hat{\alpha}$ é suficientemente negativo.

Por Que a Distribuição Não É a t de Student

Toda a teoria que garante que um teste t funciona (o estimador ser aproximadamente normal em amostras grandes) é construída assumindo que a **série é estacionária**. Mas aqui H_0 diz o **contrário**: y_t não é estacionária (tem raiz unitária) sob a hipótese nula.

Em outras palavras: estamos testando **sob a hipótese nula** um cenário em que as ferramentas usuais (que pressupõem estacionariedade) **não se aplicam**. Por isso:

- o estimador $\hat{\alpha}$ não tem, sob H_0 , a distribuição normal de sempre;
- Dickey e Fuller tiveram que derivar (por simulação) uma distribuição **própria** para essa estatística;
- essa distribuição tem caudas mais espessas à esquerda: por isso os valores críticos são **mais negativos** que os da t usual.

Calculando a Estatística do Teste

Suponha uma série com $T + 1$ observações, $y_0, y_1, \dots, y_T$. O teste segue os mesmos passos de um teste t convencional (só a distribuição de referência é diferente).

Estime α por MQO e subtraia como no slide anterior:

$$\hat{\alpha} = \frac{\sum_{t=1}^T y_{t-1} \Delta y_t}{\sum_{t=1}^T y_{t-1}^2}$$

Calcule a variância amostral e o erro-padrão:

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (\Delta y_t - \hat{\alpha} y_{t-1})^2, \quad s(\hat{\alpha}) = \sqrt{\frac{s^2}{\sum_{t=1}^T y_{t-1}^2}}$$

Obtenha a estatística do teste:

$$\tau = \frac{\hat{\alpha}}{s(\hat{\alpha})}$$

Três Especificações do Teste DF

Equações estimadas

Caso	Equação	Quando usar	Notação
1. Sem constante	$\Delta y_t = \alpha y_{t-1} + \varepsilon_t$	Série em torno de zero	τ
2. Com constante	$\Delta y_t = c + \alpha y_{t-1} + \varepsilon_t$	Série com média não-nula	τ_μ
3. Com tendência	$\Delta y_t = c + \beta t + \alpha y_{t-1} + \varepsilon_t$	Série com tendência visível	τ_τ

Como escolher?

- Olhe o gráfico da série antes de testar
- Tendência visível $\rightarrow$ inclua tendência (caso 3)
- Oscila em torno de nível não-nulo $\rightarrow$ caso 2
- Cada caso tem **seus próprios valores críticos**

Referência de valores críticos (caso 2, $T = 100$)

Nível 1% -3,51

Nível 5% -2,89

Nível 10% -2,58

Distribuição não padrão

A estatística $\tau = \hat{\alpha}/\text{ep}(\hat{\alpha})$ sob H_0 **não** segue a distribuição t de Student. Ela segue a **distribuição Dickey-Fuller**, com caudas mais espessas à esquerda e valores críticos mais negativos.

Regra de decisão

Resultado	Conclusão
-----------	-----------

$\tau < VC_{DF}$	Rejeita H_0 : série estacionária
------------------	---

$\tau \geq VC_{DF}$	Não rejeita H_0 : raiz unitária
---------------------	--

O valor crítico é negativo: rejeita-se H_0 apenas quando a estatística é suficientemente negativa.

Seção 2.4

Teste de Dickey-Fuller Aumentado (ADF)

Por Que Aumentar o Teste DF?

O teste DF simples supõe que o erro ε_t é **ruído branco**. Mas, na prática, muitas séries seguem um $AR(p)$ com $p > 1$ com raiz unitária:

$$y_t = \mu + \phi_1 y_{t-1} + \cdots + \phi_{p-1} y_{t-p+1} + \phi_p y_{t-p} + \varepsilon_t.$$

Se isso ocorre, estimarmos $\Delta y_t = \alpha y_{t-1} + \varepsilon_t$ numa série que na verdade é um $AR(p)$, o erro estimado carrega autocorrelação residual, distorcendo a estatística τ e o poder do teste.

Solução: incluir defasagens de Δy_t como variáveis explicativas, “absorvendo” a autocorrelação que sobraria no erro. Isso é o **teste de Dickey-Fuller Aumentado (ADF)**.

Exemplo: do AR(2) com Raiz Unitária até o ADF

Considere um AR(2) com raiz unitária, $y_t = \mu + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$.

Passo 1. Somar e subtrair $\phi_2 y_{t-1}$:

$$y_t = \mu + (\phi_1 + \phi_2) y_{t-1} - \phi_2 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

Passo 2. Agrupar os dois últimos termos em y_{t-1} como $-\phi_2 \Delta y_{t-1}$:

$$y_t = \mu + (\phi_1 + \phi_2) y_{t-1} - \phi_2 (y_{t-1} - y_{t-2}) + \varepsilon_t = \mu + (\phi_1 + \phi_2) y_{t-1} - \phi_2 \Delta y_{t-1} + \varepsilon_t$$

Passo 3. Subtrair y_{t-1} dos dois lados:

$$\Delta y_t = \mu + \underbrace{(\phi_1 + \phi_2 - 1)}_{\alpha} y_{t-1} - \underbrace{\phi_2}_{\lambda_1} \Delta y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \mu + \alpha y_{t-1} + \lambda_1 \Delta y_{t-1} + \varepsilon_t$$

Antes de generalizar para o AR(p), repare na equação em caixa do slide anterior:

- Δy_{t-1} é só uma **variável de controle extra**: adicionamos a diferença defasada para capturar a parte do passado que o AR(1) simples não captura.
- O teste de interesse continua sendo sobre α , o coeficiente de y_{t-1} . Igual no DF simples.
- Δy_{t-1} é adicionado só para **“limpar” o erro** de autocorrelação; o teste em si não muda, apenas melhora a sua qualidade.

Generalizando para o AR(p)

Adicione e subtraia $\phi_p y_{t-p+1}$ na equação anterior:

$$y_t = \mu + \phi_1 y_{t-1} + \cdots + (\phi_{p-1} + \phi_p) y_{t-p+1} - \phi_p \Delta y_{t-p+1} + \varepsilon_t.$$

Repetindo o mesmo procedimento com $(\phi_{p-1} + \phi_p) y_{t-p+2}$, e assim sucessivamente, $p - 1$ vezes, obtém-se ao final:

$$\Delta y_t = \mu + \alpha y_{t-1} + \sum_{i=1}^{p-1} \lambda_i \Delta y_{t-i} + \varepsilon_t$$

em que

$$\alpha = \left(\sum_{i=1}^p \phi_i \right) - 1, \quad \lambda_i = - \sum_{j=i}^{p-1} \phi_{j+1}.$$

As hipóteses continuam as mesmas do DF simples:

$$H_0: \alpha = 0 \text{ (raiz unitária)} \quad H_1: \alpha < 0 \text{ (estacionário)}$$

Apesar de incluirmos os termos Δy_{t-i} , os **valores críticos são os mesmos** da distribuição de Dickey-Fuller.

Como Escolher o Número de Defasagens p ?

O número de defasagens deve ser tal que os resíduos estimados sejam ruído branco. Poucas defasagens não “branqueiam” os resíduos, afetando a distribuição de $\hat{\alpha}$; defasagens em excesso reduzem o poder do teste, por reduzir os graus de liberdade. Há duas possibilidades:

1. Acrescentar defasagens suficientes para que os resíduos fiquem isentos de autocorrelação, verificado pelo teste de Ljung-Box.
2. Fixar um $p_{\max}$ razoavelmente alto, estimar para $p_{\max}, p_{\max} - 1, \dots, 0$, e escolher o p que minimiza um critério de informação (Akaike, Schwarz ou Hannan-Quinn), ou usando testes convencionais até rejeitar a nula a 20% de significância.

Cuidado

Poucas defasagens deixam o erro autocorrelacionado (distorce o teste); defasagens demais reduzem os graus de liberdade e o poder do teste. O equilíbrio deve garantir resíduos **sem** autocorrelação com o **menor** número de parâmetros possível.

Seção 2.5

Exercícios

Enunciado

Seja o processo auto-regressivo: $y_t = \phi y_{t-1} + \varepsilon_t$. Julgue as afirmativas como **Verdadeiro (V)** ou **Falso (F)**:

- (a) O processo é estacionário para $\phi < 1$.
- (b) Se $\phi = 1$, o processo é dito um caminho aleatório (*random walk*).
- (c) O estimador de mínimos quadrados ordinários do parâmetro ϕ é não tendencioso.
- (d) A estatística t de Student pode ser usada para testar a presença de raiz unitária.
- (e) O processo pode ser escrito na forma alternativa $\Delta y_t = \delta y_{t-1} + \varepsilon_t$, em que $\delta = \phi - 1$ e $\Delta y_t = y_t - y_{t-1}$.

- (a) F A condição correta é $|\phi| < 1$. Se $\phi = -1,2$, por exemplo, temos $\phi < 1$ mas o processo *não* é estacionário.
- (b) V $\phi = 1 \Rightarrow y_t = y_{t-1} + \varepsilon_t$: definição do passeio aleatório.
- (c) F O estimador MQO de ϕ é **tendencioso** quando $\phi \approx 1$. Sob H_0 : raiz unitária, sua distribuição não é centrada em ϕ .
- (d) F Sob H_0 , a estatística t **não** segue a distribuição t de Student. Deve-se usar os valores críticos de Dickey-Fuller.
- (e) V $y_t - y_{t-1} = (\phi - 1)y_{t-1} + \varepsilon_t = \delta y_{t-1} + \varepsilon_t$, com $\delta = \phi - 1$. Essa é a forma usada no teste DF para detectar raiz unitária.

Reformulação DF

$$y_t = \phi y_{t-1} + \varepsilon_t$$

$$\Downarrow (-y_{t-1})$$

$$\Delta y_t = \delta y_{t-1} + \varepsilon_t$$

$$\delta = \phi - 1$$

$$H_0: \delta = 0$$

$$H_1: \delta < 0$$

Enunciado

Julgue as afirmativas como **Verdadeiro (V)** ou **Falso (F)**:

- (a) Toda série temporal estacionária com variância finita pode ser escrita como um modelo de média móvel com termo de erro serialmente não correlacionado.
- (b) Um modelo de séries temporais não estacionário tem pelo menos uma raiz unitária.
- (c) O teste de Dickey-Fuller é monocaudal.
- (d) Um modelo AR(2) dado por $Y_t = a + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$ será estacionário se $\phi_1 < 1$ e $\phi_2 < 1$.
- (e) Um passeio aleatório é um processo estacionário.

- (a) V Todo processo estacionário com variância finita admite uma representação de médias móveis (possivelmente infinita) com inovações não correlacionadas – é a mesma ideia da representação $AR(1) = MA(\infty)$ que vimos no Capítulo 1, só que agora generalizada para qualquer processo estacionário.
- (b) V Não-estacionariedade do tipo raiz unitária implica que o polinômio AR tem pelo menos uma raiz no círculo unitário.
- (c) V $H_1: \delta < 0$: a rejeição ocorre apenas à **esquerda**. O teste é unicaudal.
- (d) F Para $AR(2)$, a condição correta exige que as raízes de $1 - \phi_1 z - \phi_2 z^2 = 0$ estejam fora do círculo unitário, o que impõe três

$AR(2)$: condições de estacionariedade

$$\phi_1 + \phi_2 < 1$$

$$\phi_2 - \phi_1 < 1$$

$$|\phi_2| < 1$$

Apenas $\phi_1 < 1$ e $\phi_2 < 1$
não são suficientes.

Enunciado

Considere o seguinte processo: $Y_t = \delta + Y_{t-1} + u_t$, $t = 1, 2, \dots$, em que $Y_0 = 2$ e $u_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

Julgue as afirmativas como **Verdadeiro (V)** ou **Falso (F)**:

- (a) $\mathbb{E}(Y_t) = 2$
- (b) Y_t é um processo não-estacionário.
- (c) Se $\delta = 0$, Y_t é um processo estacionário.
- (d) $\text{Var}(Y_t) = t\sigma^2$
- (e) Definindo $\Delta Y_t = Y_t - Y_{t-1}$, o processo ΔY_t é estacionário.

- (a) F Por iteração: $Y_t = Y_0 + t\delta + \sum_{i=1}^t u_i$.
Logo $\mathbb{E}(Y_t) = 2 + t\delta$, que **depende de** t se $\delta \neq 0$.
- (b) V $\text{Var}(Y_t) = t\sigma^2$ cresce com t : segunda condição de estacionariedade violada.
- (c) F Mesmo com $\delta = 0$: $\text{Var}(Y_t) = t\sigma^2 \rightarrow \infty$. A variância cresce — o processo **ainda** é não estacionário.
- (d) V $Y_t = Y_0 + t\delta + \sum_{i=1}^t u_i \Rightarrow \text{Var}(Y_t) = t\sigma^2$.
✓
- (e) V $\Delta Y_t = \delta + u_t$: constante mais ruído branco $\Rightarrow$ processo estacionário.

Passeio aleatório com drift

$$Y_t = \underbrace{Y_0 + \delta t}_{\text{tend. det.}} + \underbrace{\sum_{i=1}^t u_i}_{\text{tend. estoc.}}$$

$$\mathbb{E}(Y_t) = 2 + \delta t$$

$$\text{Var}(Y_t) = t\sigma^2$$

$$\Delta Y_t = \delta + u_t \sim I(0)$$

Conceitos revisados

- Tendência determinística vs. estocástica – e como reconhecer cada uma
- Choques permanentes ($I(1)$) vs. temporários ($I(0)$)
- Processos integrados $I(d)$: d diferenciações para $I(0)$
- Passeio aleatório: $\text{Var}(y_t) = t\sigma^2$ e o porquê da imprevisibilidade
- Passeio aleatório com drift: $\mathbb{E}(y_t) = y_0 + ct$
- Por que o teste DF usa uma distribuição não padrão

Para a próxima aula

- Tendência determinística (*trend-stationary*)
- Distinguir $I(1)$ de tendência determinística
- Modelos SARIMA
- Sazonalidade estocástica e determinística

Takeaway:

Num processo $I(1)$, choques são **permanentes**. Diferenciar remove a tendência estocástica — mas **não deve ser feito** se a tendência for determinística (Capítulo 3).

Dúvidas?

Próxima aula: Processos com Tendência Determinística